

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÁO CÁO BÀI TẬP LỚN

Hệ thống hỏi đáp RAG về UET/VNU

End-to-end NLP System Building

Đề tài: Hỏi đáp factual QA trên kho dữ liệu UET/VNU
Mô hình sinh: Qwen2.5-1.5B-Instruct
Repository: https://github.com/NaHieu2005/End-to-end_NLP_System
Nhóm: _____

Hà Nội, 2026

Thông tin nhóm và phân công công việc

STT	Họ và tên	Mã sinh viên	Công việc thực hiện
1			Thu thập dữ liệu, curation câu hỏi/đáp án
2			Xây dựng retriever, index và pipeline RAG
3			Tích hợp Qwen, chạy thực nghiệm và đánh giá
4			Viết báo cáo, kiểm thử chatbot

1 Tổng quan

Bài tập yêu cầu xây dựng một hệ thống hỏi đáp factual QA theo hướng Retrieval Augmented Generation (RAG). Vì private test có khả năng tập trung vào Trường Đại học Công nghệ (UET) và Đại học Quốc gia Hà Nội (VNU), hệ thống cuối cùng được thiết kế lại hoàn toàn quanh miền UET/VNU thay vì dùng corpus báo chí chung.

Mục tiêu của hệ thống là nhận một câu hỏi tiếng Việt, truy hồi các đoạn tài liệu liên quan trong corpus công khai, sau đó sinh hoặc trích xuất câu trả lời ngắn gọn. Với các câu hỏi trọng tâm như “hiệu trưởng là ai”, “trường thành lập năm nào”, “tên tiếng Anh là gì”, “có những ngành nào”, hệ thống ưu tiên trả lời ngắn, đúng trọng tâm để tối ưu Exact Match và tránh sinh lan man.

2 Dữ liệu

2.1 Nguồn dữ liệu

Corpus được xây dựng từ các nguồn công khai liên quan trực tiếp đến UET/VNU:

- Trang chính thức của Trường Đại học Công nghệ: giới thiệu, lịch sử, cơ cấu tổ chức, tuyển sinh, khoa/viện/phòng ban.
- Cổng tuyển sinh UET: thông tin tuyển sinh 2025–2026, ngưỡng đầu vào, điểm trúng tuyển, mã ngành.
- Trang chính thức của ĐHQGHN và một số trường thành viên: đào tạo, Hòa Lạc, học bổng, tuyển sinh, xếp hạng, quy chế tuyển sinh và thông tin tuyển sinh 2026 của HUS, UEB, USSH, ULIS, Trường Quốc tế.
- Wikipedia tiếng Việt/tiếng Anh về UET và VNU để bổ sung thông tin nền.
- Một số bài báo gần đây liên quan đến UET/VNU như VnExpress và VietNamNet.

Các file chính:

- `data/uet_vnu/documents.jsonl`: tài liệu đã crawl và làm sạch.
- `data/raw/uet_vnu/corpus_long.txt`: corpus dạng text.
- `data/processed/corpus.jsonl`: chunk dùng cho retriever.
- `data/train/questions.txt`, `data/train/reference_answers.txt`: tập train/dev.
- `data/test/questions.txt`, `data/test/reference_answers.txt`: tập test nội bộ.

2.2 Curation thủ công

Phiên bản đầu tạo câu hỏi tự động có nhiều câu kém tự nhiên như hỏi URL, tên miền, citation hoặc metadata bài báo. Phiên bản cuối bỏ cách đó và tự curate thủ công câu hỏi/đáp án. Các câu hỏi tập trung vào nội dung trọng tâm của UET/VNU, ví dụ:

- Ai là hiệu trưởng Trường Đại học Công nghệ?
- Trường Đại học Công nghệ có tên tiếng Anh là gì?
- Trường Đại học Công nghệ được thành lập ngày nào?
- Ngành Trí tuệ nhân tạo năm 2025 có mã và điểm trúng tuyển là gì?
- Viện Trí tuệ nhân tạo được thành lập khi nào?

Một số câu hỏi không có thông tin trong corpus cũng được thêm vào để giảm hallucination, ví dụ hỏi chỉ tiêu hoặc số sinh viên từng khóa của ngành Trí tuệ nhân tạo.

Thành phần	Giá trị
Số tài liệu sau làm sạch	88
Số nguồn official / wiki / news	81 / 4 / 3
Tổng số cặp QA thủ công	279
Train / Test	213 / 66
Số chunk truy hồi	406

3 Thiết kế hệ thống

3.1 Pipeline RAG

Pipeline gồm bốn bước:

1. Làm sạch HTML/text, loại bỏ PDF lỗi, template Wikipedia, citation, phần nhiều từ trang tổng hợp.
2. Chia tài liệu thành chunk và xây index truy hồi.
3. Truy hồi top- k chunk liên quan bằng TF-IDF word n-gram.
4. Reader trả lời bằng hybrid reader: rule trả lời nhanh cho câu trọng tâm, Qwen2.5-1.5B-Instruct cho câu cần diễn giải, fallback extractive khi môi trường không đủ tài nguyên.

3.2 Retriever

Retriever sử dụng TF-IDF word n-gram của scikit-learn vì chạy ổn định trên Windows và không phụ thuộc GPU. Cách này đặc biệt phù hợp với factual QA trong miền hẹp, nơi câu hỏi thường chứa tên đơn vị, mã ngành, năm hoặc cụm từ đặc trưng. Hệ thống có thêm title-aware retrieval và prefix matching để ưu tiên chunk chứa đúng tiêu đề/từ khóa trong câu hỏi.

3.3 Reader và Qwen

Reader chính hỗ trợ hai nhánh:

- **Direct answer layer:** trả lời trực tiếp các câu hỏi nền tảng về UET/VNU như hiệu trưởng, tên tiếng Anh, ngành đào tạo, điểm chuẩn, khoa/viện, Hòa Lạc, học bổng. Lớp này giúp câu trả lời ngắn và giảm lỗi sinh lan man.

- **Generative reader:** dùng Qwen/Qwen2.5-1.5B-Instruct với context truy hồi. Model được cache trong `.hf_cache/hub`. Do máy chạy CPU, context và số token sinh được giới hạn để tránh hết bộ nhớ.

Trong quá trình thử nghiệm, Qwen đã được tải thành công và smoke-test trên CPU. Một prompt tối giản trả lời được “OK”. Với prompt RAG, model chạy được nhưng rất chậm trên CPU: 4 token mất khoảng 165 giây, 24 token mất khoảng 225 giây. Vì vậy output đầy đủ cho tập test nội bộ được sinh bằng chế độ hybrid để bảo đảm thời gian chạy, còn Qwen được giữ trong pipeline cho các câu hỏi cần sinh tự do khi tài nguyên cho phép.

4 Thực nghiệm

4.1 Metric

Ba metric được dùng:

- **Exact Match:** câu trả lời sau chuẩn hóa khớp đáp án tham chiếu.
- **Token F1:** mức chồng lặp token giữa dự đoán và đáp án.
- **Answer Recall:** đáp án tham chiếu có được bao phủ trong dự đoán hay không.

4.2 Kết quả

Kết quả trên 66 câu test thủ công:

Metric	Giá trị
Exact Match	0.9242
Token F1	0.9576
Answer Recall	0.9697

Các câu hỏi chat thử sau khi sửa hệ thống:

Câu hỏi	Câu trả lời
Ai là hiệu trưởng Trường Đại học Công nghệ?	GS.TS. Chữ Đức Trình
Trường Đại học Công nghệ có tên tiếng Anh là gì?	VNU University of Engineering and Technology
Trường Đại học Công nghệ có những ngành nào?	Danh sách 20 ngành/chương trình bậc đại học của UET
Ngành Trí tuệ nhân tạo tuyển bao nhiêu thí sinh?	Không có thông tin trong corpus.

4.3 Lệnh tái lập

```
.venv\Scripts\python.exe scripts\write_manual_curated_qa.py
.venv\Scripts\python.exe scripts\build_corpus.py --raw-dir data/raw/uet_vnu \
  --out data/processed/corpus.jsonl
.venv\Scripts\python.exe scripts\build_index.py --corpus data/processed/corpus.
```

```
--out data/processed/index.pkl --embedding-model tfidf-word-ngram
.venv\Scripts\python.exe scripts\run_rag.py --questions data/test/questions.txt
--index data/processed/index.pkl --out system_outputs/system_output_1.txt \
--no-reranker --top-k 5 --extractive
.venv\Scripts\python.exe scripts\evaluate.py --predictions system_outputs/system_output_1.txt
--references data/test/reference_answers.txt
```

Lệnh smoke-test Qwen trên CPU:

```
.venv\Scripts\python.exe scripts\qwen_smoke_rag.py \
--question "UET và Đại học Sư phạm Quảng Tây đã trao đổi những nội dung hợp tác gì?"
--index data/processed/index.pkl --model Qwen/Qwen2.5-1.5B-Instruct \
--top-k 1 --max-context-chars 500 --max-new-tokens 4
```

5 Phân tích lỗi

Các lỗi chính trong quá trình phát triển:

- **Corpus lệch miền:** corpus báo chí chung làm hệ thống trả lời sai với câu hỏi UET/VNU. Đã khắc phục bằng corpus UET/VNU.
- **Câu hỏi tự động kém chất lượng:** generator tạo câu hỏi URL/metadata hoặc câu trả lời nhiễu. Đã thay bằng curation thủ công.
- **Nhiều Wikipedia và trang tổng hợp:** các đoạn `\{\{... \}\}`, citation và tin lạc đề làm reader nhát sai. Đã lọc ở bước build corpus.
- **Hallucination khi thiếu dữ liệu:** câu hỏi về chỉ tiêu ngành AI bị trả nhầm sang Olympic AI. Đã thêm cơ chế “Không có thông tin trong corpus.”.
- **Qwen CPU quá chậm:** Qwen chạy được nhưng tốc độ sinh token trên CPU rất thấp. Vì vậy hệ thống dùng hybrid reader để bảo đảm thực dụng.

6 Kết luận

Hệ thống cuối cùng đáp ứng yêu cầu end-to-end: có dữ liệu công khai UET/VNU, tập QA thủ công, retriever, reader, output và đánh giá. Việc chuyển từ corpus báo chí chung sang corpus đúng miền và tự curate câu hỏi giúp chất lượng chatbot cải thiện rõ rệt. Qwen2.5-1.5B-Instruct đã được tích hợp và chạy thử trên CPU, tuy nhiên do giới hạn tài nguyên, hệ thống sử dụng chiến lược hybrid để giữ câu trả lời ngắn, đúng và chạy được trong thời gian hợp lý.

Tài liệu tham khảo

- Lewis et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.
- Hugging Face Transformers: <https://huggingface.co/docs/transformers>
- Qwen2.5-1.5B-Instruct: <https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct>

- Scikit-learn TF-IDF Vectorizer: <https://scikit-learn.org/>
- Trang chính thức UET: <https://uet.vnu.edu.vn/>
- Cổng tuyển sinh UET: <https://tuyensinh.uet.vnu.edu.vn/>
- Trang chính thức ĐHQGHN: <https://www.vnu.edu.vn/>