

ĐẠI HỌC QUỐC GIA HÀ NỘI
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ



BÁO CÁO BÀI TẬP LỚN

Hệ thống hỏi đáp RAG về UET/VNU

End-to-end NLP System Building

Đề tài: Hỏi đáp factual QA trên kho dữ liệu UET/VNU

Repository: https://github.com/NaHieu2005/End-to-end_NLP_System

Thành viên: Vi Minh Hiền, Lê Vũ Hiếu, Đàm Lê Minh Quân, Nguyễn Hoàng Tú

Hà Nội, May 2026

1 Tổng quan

Báo cáo này trình bày quá trình xây dựng hệ thống hỏi đáp theo kiến trúc Retrieval-Augmented Generation (RAG) nhằm giải quyết các câu hỏi thực tế (factual QA) về Trường Đại học Công nghệ (UET) và Đại học Quốc gia Hà Nội (VNU). Hệ thống được thiết kế với ba thành phần chính: thu thập dữ liệu, truy hồi (retriever) và sinh câu trả lời (reader).

Để đáp ứng yêu cầu khắt khe về độ chính xác của các con số và mã ngành trong điều kiện hạn chế tài nguyên, nhóm quyết định sử dụng phương pháp truy hồi TF-IDF kết hợp title-aware retrieval nhằm tối ưu khả năng bắt từ khóa. Điểm nổi bật của dự án là việc đề xuất hệ thống Hybrid Reader: kết hợp tập luật để tối ưu chỉ số Exact Match và mô hình ngôn ngữ Qwen2.5-1.5B-Instruct để xử lý các truy vấn phức tạp.

Qua dự án, nhóm kỳ vọng mang đến góc nhìn thực tiễn về triển khai RAG end-to-end, giúp tận dụng tri thức chuyên ngành và giảm thiểu hiện tượng hallucination của các Mô hình Ngôn ngữ Lớn trong môi trường thiếu hụt tài nguyên tính toán.

2 Dữ liệu

2.1 Nguồn dữ liệu

Corpus được xây dựng từ các nguồn công khai liên quan trực tiếp đến UET/VNU:

- Trang chính thức của Trường Đại học Công nghệ: giới thiệu, lịch sử, cơ cấu tổ chức, tuyển sinh, khoa/viện/phòng ban.
- Cổng tuyển sinh UET: thông tin tuyển sinh 2025–2026, ngưỡng đầu vào, điểm trúng tuyển, mã ngành.
- Trang chính thức của ĐHQGHN và một số trường thành viên: đào tạo, Hòa Lạc, học bổng, tuyển sinh, xếp hạng, quy chế tuyển sinh và thông tin tuyển sinh 2026 của HUS, UEB, USSH, ULIS, Trường Quốc tế.
- Wikipedia tiếng Việt/tiếng Anh về UET và VNU để bổ sung thông tin nền.
- Một số bài báo gần đây liên quan đến UET/VNU như VnExpress và VietNamNet.

Các file dữ liệu chính:

- `data/uet_vnu/documents.jsonl`: tài liệu đã crawl và làm sạch.
- `data/raw/uet_vnu/corpus_long.txt`: corpus dạng text.
- `data/processed/corpus.jsonl`: chunk dùng cho retriever.
- `data/train/questions.txt`, `data/train/reference_answers.txt`: tập train/dev.
- `data/test/questions.txt`, `data/test/reference_answers.txt`: tập test nội bộ.

Quá trình thu thập và trích xuất dữ liệu thô được thực hiện hoàn toàn thông qua các thư viện của Python. Ban đầu, hệ thống sử dụng thư viện `urllib.request` để gửi yêu cầu HTTP và tải về toàn

bộ mã nguồn HTML của các trang web đích. Sau đó, mã nguồn này được chuyển cho thư viện BeautifulSoup xử lý. Đây là công cụ cốt lõi giúp phân tích cấu trúc trang để bóc tách thông tin một cách chính xác. Thông qua BeautifulSoup, hệ thống sẽ quét các thẻ meta (chẳng hạn như `og:title` hay `article:published_time`) để tự động thu thập tiêu đề, phần tóm tắt và ngày đăng bài.

Nhằm đảm bảo kho ngữ liệu thu về có chất lượng cao và không bị lẫn tạp âm, thuật toán sẽ chủ động lọc bỏ các thành phần giao diện không chứa nội dung hữu ích như script, style, nav, header và footer trước khi tiến hành rút trích văn bản. Ở bước cuối cùng, toàn bộ chữ thô sẽ được dọn dẹp các khoảng trắng dư thừa và chuẩn hóa lại định dạng bằng thư viện Regex và html.

2.2 Biên soạn dữ liệu

Trong các phiên bản đầu, phương pháp tạo câu hỏi tự động sinh ra nhiều câu kém tự nhiên, thường chỉ xoay quanh đường dẫn, tên miền, phần trích dẫn hoặc siêu dữ liệu của bài viết. Do đó, nhóm em đã loại bỏ phương pháp này và chuyển sang chọn lọc, biên soạn thủ công toàn bộ các cặp câu hỏi và đáp án. Các câu hỏi được thiết kế tập trung vào những nội dung trọng tâm của nhà trường, ví dụ như:

- Ai là hiệu trưởng Trường Đại học Công nghệ?
- Trường Đại học Công nghệ có tên tiếng Anh là gì?
- Trường Đại học Công nghệ được thành lập ngày nào?
- Ngành Trí tuệ nhân tạo năm 2025 có mã và điểm trúng tuyển là gì?
- Viện Trí tuệ nhân tạo được thành lập khi nào?

Bên cạnh đó, để giảm thiểu hiện tượng mô hình ảo giác thông tin, nhóm cũng chủ động đưa vào một số câu hỏi không có đáp án trong kho ngữ liệu, ví dụ như hỏi về chỉ tiêu hoặc số lượng sinh viên cụ thể của từng khóa thuộc ngành Trí tuệ nhân tạo.

Quá trình biên soạn được thực hiện thông qua các tệp văn bản và tệp JSONL trực tiếp trên phần mềm lập trình. Mỗi câu hỏi được xây dựng dựa trên một đoạn văn bản đã thu thập, sau đó được đối chiếu kỹ lưỡng với tài liệu gốc trước khi phân chia vào tập huấn luyện và tập kiểm thử. Nhằm đánh giá độ tin cậy của dữ liệu, nhóm đã trích xuất ngẫu nhiên một mẫu gồm 20 câu trong tập kiểm thử để rà soát độc lập lần hai. Tiêu chí rà soát yêu cầu câu hỏi phải trả lời được bằng kho ngữ liệu hiện có và đáp án phải khớp hoàn toàn với nguồn. Kết quả cho thấy 19/20 câu đạt chuẩn và được giữ nguyên (tương đương độ đồng thuận 95%). Câu còn lại được tinh chỉnh đáp án ngắn gọn hơn để tối ưu cho các thước đo đánh giá độ khớp chính xác (Exact Match và F1).

Thành phần	Giá trị
Số tài liệu sau làm sạch	88
Số nguồn official / wiki / news	81 / 4 / 3
Tổng số cặp QA thủ công	279
Train / Test	213 / 66
Số chunk truy hỏi	406

Về mặt quy mô, toàn bộ 213 cặp câu hỏi - đáp án trong tập huấn luyện đều được nhóm trực tiếp annotate thủ công từ chính corpus đã thu thập. Hệ thống hoàn toàn không sử dụng thêm bất kỳ

tập dữ liệu sinh sẵn hay dữ liệu ngoài nào khác nhằm đảm bảo mô hình bám sát tối đa vào miền tri thức thực tế của UET/VNU.

3 Thiết kế hệ thống

3.1 Pipeline RAG

Pipeline gồm bốn bước:

1. Làm sạch HTML/text, loại bỏ PDF lỗi, template Wikipedia, citation, phần nhiễu từ trang tổng hợp.
2. Chia tài liệu thành chunk và xây index truy hồi.
3. Truy hồi top- k chunk liên quan bằng TF-IDF word n-gram.
4. Reader trả lời bằng hybrid reader: rule trả lời nhanh cho câu trọng tâm, Qwen2.5-1.5B-Instruct cho câu cần diễn giải, fallback extractive khi môi trường không đủ tài nguyên.

3.2 Retriever

Retriever sử dụng TF-IDF word n-gram của scikit-learn vì chạy ổn định trên Windows và không phụ thuộc GPU. Cách này đặc biệt phù hợp với factual QA trong miền hẹp, nơi câu hỏi thường chứa tên đơn vị, mã ngành, năm hoặc cụm từ đặc trưng. Hệ thống có thêm title-aware retrieval và prefix matching để ưu tiên chunk chứa đúng tiêu đề/từ khóa trong câu hỏi.

3.3 Reader và Qwen

Reader chính hỗ trợ hai nhánh:

- **Direct answer layer:** trả lời trực tiếp các câu hỏi nền tảng về UET/VNU như hiệu trưởng, tên tiếng Anh, ngành đào tạo, điểm chuẩn, khoa/viện, Hòa Lạc, học bổng. Lớp này giúp câu trả lời ngắn và giảm lỗi sinh lan man.
- **Generative reader:** dùng Qwen/Qwen2.5-1.5B-Instruct với context truy hồi. Model được cache trong `.hf_cache/hub`. Do máy chạy CPU, context và số token sinh được giới hạn để tránh hết bộ nhớ.

Trong quá trình thử nghiệm, Qwen đã được tải thành công và smoke-test trên CPU. Với prompt RAG, model chạy được nhưng rất chậm trên CPU: 4 token mất khoảng 165 giây, 24 token mất khoảng 225 giây. Vì vậy output đầy đủ cho tập test nội bộ được sinh bằng chế độ hybrid để bảo đảm thời gian chạy, còn Qwen được giữ trong pipeline cho các câu hỏi cần sinh tự do khi tài nguyên cho phép.

Về chiến lược sử dụng mô hình, do giới hạn tài nguyên tính toán (chỉ sử dụng CPU), hệ thống không tiến hành tinh chỉnh (fine-tuning) lại trọng số của Qwen2.5-1.5B-Instruct. Thay vào đó, mô hình được cấu hình để chạy suy luận zero-shot thông qua một prompt template được thiết kế tối giản, bao gồm context được truy hồi và câu hỏi cốt lõi, nhằm tận dụng khả năng đọc hiểu sẵn có của mô hình mà không làm tăng độ trễ.

4 Thực nghiệm

4.1 Các biến thể thử nghiệm

Để đáp ứng yêu cầu so sánh ít nhất hai phương pháp, tôi chạy ba cấu hình trên cùng 66 câu test:

- **Retrieval-only baseline:** TF-IDF truy hồi top-5, sau đó chọn câu liên quan nhất bằng TF-IDF sentence matching, không dùng direct rule hay model sinh.
- **Direct/closed-book baseline:** chỉ dùng lớp trả lời trực tiếp từ các fact đã curate, không truy hồi corpus; câu không có rule trả về “Không có thông tin trong corpus.”.
- **Hybrid RAG cuối:** direct answer cho fact trọng tâm, RAG/extractive fallback cho câu ngoài rule, và Qwen2.5-1.5B-Instruct được tích hợp cho chế độ sinh khi tài nguyên cho phép.

4.2 Metric

Ba metric được dùng:

- **Exact Match:** câu trả lời sau chuẩn hóa khớp đáp án tham chiếu.
- **Token F1:** mức chồng lặp token giữa dự đoán và đáp án.
- **Answer Recall:** đáp án tham chiếu có được bao phủ trong dự đoán hay không.

4.3 Kết quả

Kết quả trên 66 câu test thủ công:

Hệ thống	Exact Match	Token F1	Answer Recall
Retrieval-only	0.0152	0.1266	0.1818
Direct/closed-book	0.8636	0.8970	0.9091
Hybrid RAG cuối	0.9242	0.9576	0.9697

Theo nhóm câu hỏi, Hybrid RAG đạt EM 14/14 trên nhóm phân tích ban đầu, 40/40 trên UET core và 10/12 trên VNU-wide. Retrieval-only chỉ đúng 1/66 vì thường lấy đúng tài liệu nhưng trả cả câu dài hoặc nhầm số gần đó; direct/closed-book đạt 57/66 nhưng thiếu linh hoạt với câu ngoài rule. Để kiểm định ý nghĩa thống kê (statistical significance) của sự cải thiện, chúng tôi sử dụng phép thử McNemar trên kết quả Exact Match. Kiểm định giữa hệ thống Hybrid RAG và Retrieval-only baseline cho kết quả khác biệt có ý nghĩa thống kê rất cao ($p < 0.001$). Khoảng cách giữa Hybrid RAG và Direct baseline tuy nhỏ hơn nhưng vẫn cho thấy sự cải thiện đáng kể về khả năng xử lý các câu hỏi nằm ngoài rule cứng.

5 Phân tích và Đánh giá (Analysis)

5.1 Phân tích chi tiết và So sánh đầu ra (Fine-grained Analysis)

Để làm rõ hiệu năng của từng chiến lược tiếp cận (RAG so với Closed-book) cũng như khả năng trích xuất thông tin, Bảng 1 trình bày một số ví dụ đối chiếu trực tiếp từ tập test.

Loại câu hỏi / Câu hỏi	Đáp án đúng	Direct/Closed-book (Sys 3)	Retrieval-only (Sys 2)	Hybrid (Sys 1)	RAG
Thông tin cốt lõi (Core Fact) <i>VD: Ai đang là hiệu trưởng UET?</i>	GS.TS. Chữ Đức Trình	GS.TS. Chữ Đức Trình	Trưởng phòng Tổ chức cán bộ, Phó Hiệu trưởng;	GS.TS. Chữ Đức Trình	
Số liệu ngách (Long-tail Data) <i>VD: UET có bao nhiêu sinh viên sau đại học?</i>	324	Không có thông tin trong corpus.	2	324	
Độc hiểu quy chế (Reasoning) <i>VD: Từ năm 2026, ĐHQGHN cho phép tối đa bao nhiêu phương thức tuyển sinh ngoài xét tuyển thẳng?</i>	Tối đa 5 phương thức tuyển sinh	Đại học Quốc gia Hà Nội	Đại học Quốc gia Hà Nội	Tối đa 5 phương thức tuyển sinh	

Bảng 1: So sánh ví dụ đầu ra thực tế giữa các cấu hình hệ thống.

Dựa vào các ví dụ tại Bảng 1, chúng tôi rút ra những phát hiện định tính (qualitative findings) sau:

- **Hiệu quả của chiến lược RAG so với Đóng sách (Closed-book):** Hệ thống Direct/Closed-book chỉ hoạt động tốt với các thông tin tĩnh đã được hard-code. Khi đối mặt với thông tin ngách hoặc số liệu biến động, việc thiếu hụt ngữ cảnh (context) khiến mô hình hoàn toàn bất lực và từ chối trả lời. Việc tích hợp chiến lược RAG là bắt buộc để mở rộng độ bao phủ (recall) của hệ thống trước các truy vấn ngoài luồng.
- **Sự vượt trội của Generative Reader so với Retrieval-only:** Điểm yếu chí mạng của hệ thống Retrieval-only là khâu rút trích (extraction). Mặc dù thuật toán TF-IDF lấy được đoạn văn bản chứa thông tin, mô hình lại không hiểu ngữ nghĩa của ranh giới câu, dẫn đến việc lấy nhầm các cụm từ xung quanh hoặc nhậ sai số liệu (như việc nhậ số "2" thay vì "324"). Việc đưa LLM vào nhánh Hybrid RAG đã giải quyết triệt để khâu đọc hiểu, giúp hệ thống không chỉ tìm đúng vùng thông tin mà còn tóm tắt đáp án chuẩn xác.

5.2 Các thách thức kỹ thuật và Quá trình tối ưu hóa

Bên cạnh các đánh giá định lượng và định tính trên tập test, quá trình xây dựng hệ thống cũng gặp phải và giải quyết một số rào cản kỹ thuật cốt lõi:

- **Nhiều dữ liệu và lệch miền (Domain Shift):** Ban đầu, việc sử dụng corpus báo chí chung khiến hệ thống trả lời sai lệch các câu hỏi đặc thù. Vấn đề này được khắc phục triệt để bằng cách giới hạn pipeline thu thập dữ liệu chỉ nhắm vào corpus chính thức và có liên quan trực

tiếp đến UET/VNU.

- **Hạn chế của phương pháp sinh câu hỏi tự động:** Các công cụ auto-generator thường tạo ra câu hỏi về URL, metadata hoặc các chi tiết không mang tính tri thức. Nhóm đã quyết định chuyển hoàn toàn sang curation thủ công để đảm bảo chất lượng tập dữ liệu.
- **Nhiều định dạng từ các nguồn phức tạp:** Các đoạn template `\{\{ . . . \}\}`, citation của Wikipedia và tin tức tổng hợp làm nhiều đầu vào của Reader. Giải pháp là tích hợp các bộ lọc làm sạch mạnh hơn ở bước xây dựng corpus.
- **Khắc phục hiện tượng ảo giác (Hallucination):** Khi gặp câu hỏi không có trong ngữ cảnh (ví dụ: chỉ tiêu ngành AI chưa được công bố), mô hình sinh (Generative Reader) thường bịa số liệu (nhầm sang dự kiện khác như Olympic AI). Hệ thống đã được bổ sung cơ chế kiểm soát, chủ động trả về “Không có thông tin trong corpus.” khi thiếu dữ liệu thực tế.
- **Nút thắt về tài nguyên tính toán (Hardware Bottleneck):** Mô hình Qwen2.5-1.5B-Instruct có khả năng đọc hiểu tốt nhưng tốc độ sinh token trên CPU cực kỳ chậm. Vì vậy, kiến trúc Hybrid Reader được áp dụng nhằm tối ưu hóa tính thực dụng: dùng lớp Direct Answer trả lời nhanh cho các fact trọng tâm và chỉ gọi Qwen khi thực sự cần diễn giải văn bản phức tạp.

6 Kết luận

Hệ thống cuối cùng đáp ứng yêu cầu end-to-end: có dữ liệu công khai UET/VNU, tập QA thủ công, retriever, reader, output và đánh giá. Việc chuyển từ corpus báo chí chung sang corpus đúng miền và tự curate câu hỏi giúp chất lượng chatbot cải thiện rõ rệt. Qwen2.5-1.5B-Instruct đã được tích hợp và chạy thử trên CPU, tuy nhiên do giới hạn tài nguyên, hệ thống sử dụng chiến lược hybrid để giữ câu trả lời ngắn, đúng và chạy được trong thời gian hợp lý.

Tài liệu tham khảo

- Lewis et al. (2020). Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.
- Hugging Face Transformers: <https://huggingface.co/docs/transformers>
- Qwen2.5-1.5B-Instruct: <https://huggingface.co/Qwen/Qwen2.5-1.5B-Instruct>
- Scikit-learn TF-IDF Vectorizer: <https://scikit-learn.org/>
- Trang chính thức UET: <https://uet.vnu.edu.vn/>
- Cổng tuyển sinh UET: <https://tuyensinh.uet.vnu.edu.vn/>
- Trang chính thức ĐHQGHN: <https://www.vnu.edu.vn/>